


LEI

LICENCIATURA
ENGENHARIA INFORMÁTICA

Relatório

Inteligência Artificial

05/2026



LEI

LICENCIATURA
ENGENHARIA INFORMÁTICA

Relatório

Inteligência Artificial

Equipa do trabalho:

8220449 Guilherme Cláudio Pereira Jorge Canha
8220442 Bruno Samuel Fernandes Carvalho

Índice

Glossário	6
1. Descrição do Caso de Uso	7
1.1 Motivação Industrial e Cenário-Alvo	7
1.2 O que o Modelo Deteta.....	7
1.3 Suposições e Restrições	7
2. Descrição do Conjunto de Dados	8
2.1 Recolha de Dados	8
2.2 Tamanho do Conjunto de Dados por Split e Classe	8
2.3 Política de Etiquetagem	9
2.4 Estratégias de Augmentation.....	9
2.5 Verificações de Qualidade	9
3. Modelo(s) e Configuração de Treino.....	10
3.1 Arquitetura e Pipeline de Treino.....	10
3.2 Hiperparâmetros.....	10
3.3 Hardware Utilizado	10
4. Resultados da Avaliação.....	11
4.1 Métricas Padrão no Conjunto de Validação	11
4.2 Análise de Resultados e Erro	11
5. Notas de Implementação.....	13
5.1 Aplicação de Demonstração	13
5.2 Velocidade de Inferência e Tamanho dos Modelos.....	15
5.3 Parâmetros e Configurações	15
5.4 Ponto de Entrada para Inferência (CLI)	15
6. Conclusões e Trabalho Futuro.....	16
7. Bibliography	17

Índice de Tabelas

Tabela 1 - Dataset Shelves	8
Tabela 2 - Dataset SKU-110K	8
Tabela 3 - Dataset Pallets.....	9
Tabela 4 - Augmentações Roboflow	9
Tabela 5 - Augmentações treino.....	9
Tabela 6 - Modelos.....	10
Tabela 7 - Hiperparâmetros	10
Tabela 8 - Métricas nos modelos	11
Tabela 9 - Análise resultados	11
Tabela 10 - Velocidade e tamanho dos modelos.....	15

Índice de Figuras

Figura 1 - Inferência	13
Figura 2 - Comparar modelos	13
Figura 3 - Webcam ao vivo.....	14
Figura 4 - Dashboard.....	14
Figura 5 - Histórico	15

Glossário

YOLOv8	You Only Look Once v8 — arquitetura de detecção de objetos em tempo real da Ultralytics.
mAP	Mean Average Precision — métrica padrão para avaliar modelos de detecção de objetos.
Bounding Box	Caixa delimitadora retangular que identifica a localização de um objeto na imagem.
Epoch	Uma passagem completa por todos os dados de treino durante o processo de aprendizagem.
Precision	Proporção de detecções corretas face ao total de detecções realizadas pelo modelo.
Recall	Proporção de objetos reais corretamente detetados face ao total de objetos existentes.
Augmentation	Técnicas de transformação aplicadas às imagens para aumentar a diversidade dos dados de treino.
IoU	Intersection over Union — medida de sobreposição entre a bounding box prevista e a real.
NMS	Non-Maximum Suppression — algoritmo que elimina detecções duplicadas sobrepostas.
Mosaic	Técnica de augmentation que combina 4 imagens numa só para enriquecer o contexto de treino.
AMP	Automatic Mixed Precision — técnica que acelera o treino usando precisão reduzida (FP16).
SKU	Stock Keeping Unit — código único de identificação de um produto em inventário.
Edge Computing	Processamento de dados junto ao dispositivo/câmara, sem necessidade de servidor remoto.

1. Descrição do Caso de Uso

1.1 Motivação Industrial e Cenário-Alvo

A gestão eficiente de inventário em ambientes de retalho e armazéns logísticos constitui um desafio operacional significativo. Atualmente, a verificação da disponibilidade de produtos nas prateleiras é feita maioritariamente de forma manual, o que é ineficiente, demorado e propenso a erros humanos. Prateleiras vazias representam vendas perdidas e insatisfação do cliente.

O presente projeto propõe uma solução de **Monitorização Inteligente de Prateleiras** baseada em visão por computador, capaz de detetar automaticamente a presença e localização de produtos em prateleiras de armazém ou supermercado. Utilizando modelos de deteção de objetos YOLOv8, o sistema pode processar imagens de prateleiras em tempo real e identificar cada item individual visível. (Jocher, 2023)

O cenário-alvo inclui:

- **Supermercados e lojas de retalho:** Monitorização contínua da ocupação das prateleiras para alertar sobre ruturas de stock.
- **Armazéns logísticos:** Verificação da correta colocação e presença de produtos nas localizações designadas.
- **Centros de distribuição:** Auditoria visual automatizada da organização do inventário.

1.2 O que o Modelo Deteta

O sistema deteta uma classe única: **item** — qualquer produto individual visível numa prateleira. Cada deteção é representada por uma caixa delimitadora (bounding box) com coordenadas normalizadas e um nível de confiança associado.

O que o sistema explicitamente NÃO cobre:

- Identificação da marca, tipo ou categoria específica de cada produto.
- Deteção de prateleiras vazias (apenas se infere indiretamente pela ausência de deteções numa zona).
- Avaliação do estado da embalagem (dano, deformação).

A decisão de utilizar uma classe única fundamenta-se no objetivo principal do caso de uso: monitorizar a **presença/ausência** de produtos para gestão de stock, e não a identificação individual de cada produto. Como trabalho futuro, planeia-se a integração de leitura de códigos QR para identificação de produtos e deteção de zonas sem stock.

1.3 Suposições e Restrições

- **Câmara:** Posicionamento frontal ou com ângulo ligeiro em relação à prateleira (até ~30°).
- **Distância:** 0.5 a 3 metros da prateleira.
- **Iluminação:** Condições de iluminação artificial interior (fluorescente ou LED). O sistema não foi validado para exteriores.
- **Fundo:** Prateleiras de retalho convencionais (metálicas ou de madeira) com produtos dispostos de forma organizada.

2. Descrição do Conjunto de Dados

2.1 Recolha de Dados

Foram utilizados dois datasets complementares, ambos focados na deteção de produtos em prateleiras:

Dataset Primário — Shelves (Dataset Curado):

- **Fonte:** Plataforma Roboflow, projeto `shelves-exlrc-bvskw`. (Roboflow, 2024)
- **Imagens:** Recolhidas e curadas a partir de imagens públicas de ambientes de retalho, cobrindo diferentes tipos de prateleiras, ângulos e condições de iluminação.
- **Anotação:** Realizada no Roboflow com bounding boxes em formato YOLOv8 (coordenadas normalizadas).

Dataset Secundário — SKU-110K (Benchmark Público): (Goldman, n.d.)

- **Fonte:** Benchmark público SKU-110K, disponível em Roboflow Universe.
- **Imagens:** ~11 762 imagens diversificadas de prateleiras de retalho, provenientes de múltiplos ambientes comerciais.
- **Justificação:** Utilizado para treinar o terceiro modelo (SKU), com o objetivo de avaliar o impacto da dimensão e diversidade do dataset na capacidade de generalização.

Dataset Terciário — Pallets (Deteção de Paletes):

- **Fonte:** Roboflow Universe — Pallet Detection Dataset.
- **Imagens:** ~972 imagens de paletes e caixotes em estantes de armazém industrial.
- **Justificação:** Utilizado para treinar o quarto modelo (Pallets), aplicando transfer learning a partir dos pesos do modelo SKU-110K, avaliando a capacidade de adaptação a um domínio diferente (logística industrial).

2.2 Tamanho do Conjunto de Dados por Split e Classe

Dataset Shelves (utilizado nos modelos Nano 50ep e Small 150ep):

Partição	Nº de Imagens
Treino	1462
Validação	151
Teste	60
Total	1673

Tabela 1 - Dataset Shelves

Dataset SKU-110K (utilizado no modelo Nano SKU):

Partição	Nº de Imagens
Treino	8 233
Validação	588
Teste	2 941
Total	11 762

Tabela 2 - Dataset SKU-110K

Dataset Pallets (utilizado no modelo Nano Pallets com transfer learning):

Partição	Nº de Imagens
Treino	680
Validação	195
Teste	97
Total	972

Tabela 3 - Dataset Pallets

Todos os datasets contêm 1 classe (`item`), com milhares de instâncias por imagem (tipicamente 20-60 produtos por prateleira).

2.3 Política de Etiquetagem

- Cada produto individual visível na prateleira é anotado com uma bounding box.
- Produtos parcialmente ocluídos (>50% visíveis) são anotados.
- Produtos completamente ocluídos são ignorados.
- Quando dois produtos estão sobrepostos, cada um recebe a sua própria caixa delimitadora, mesmo que haja sobreposição.
- Etiquetas de preço e sinalética da loja não são anotados.

2.4 Estratégias de Augmentation

Augmentações aplicadas no Roboflow (dataset Shelves):

Augmentação	Parâmetros	Justificação
Resize	Stretch para 640x640	Normalização para input do YOLOv8
Horizontal Flip	Ativado	Invariância à orientação da prateleira
Brightness	-15% a +15%	Robustez a variações de iluminação
Blur	Até 1.25 px	Simulação de câmaras de menor qualidade
Multiplicador	3x	Triplificação dos dados para maior diversidade

Tabela 4 - Augmentações Roboflow

Augmentações aplicadas durante o treino (YOLOv8, via Ultralytics):

Augmentação	Valor	Justificação
Mosaic	1.0	Combina 4 imagens para contexto variado
Flip LR	0.5	Invariância horizontal
HSV (H/S/V)	0.015 / 0.7 / 0.4	Variação de cor e iluminação
Translate	0.1	Tolerância a posicionamento da câmara
Scale	0.5	Robustez a diferentes distâncias
Erasing	0.4	Simulação de oclusão parcial

Tabela 5 - Augmentações treino

2.5 Verificações de Qualidade

- **Distribuição por classe:** Verificada como equilibrada, dado que existe apenas 1 classe.
- **Duplicados:** O Roboflow realiza verificação automática de duplicados durante o upload.
- **Consistência de etiquetas:** Verificada visualmente por amostragem aleatória de imagens anotadas.

3. Modelo(s) e Configuração de Treino

3.1 Arquitetura e Pipeline de Treino

Foram treinados 4 modelos utilizando a framework Ultralytics YOLOv8, com treino local:

Modelo	Arquitetura	Dataset	Épocas	Motivação
Nano Shelves (v1.0)	YOLOv8n	Shelves	50	Modelo base — rápido e leve
Small Shelves (v2.0)	YOLOv8s	Shelves	150	Avaliar se mais parâmetros melhoram desempenho
Nano SKU (v3.0)	YOLOv8n	SKU-110K	50	Avaliar impacto de dataset maior e mais diverso
Nano Pallets (v4.0)	YOLOv8n	Pallets	50	Transfer learning do SKU para domínio de armazém

Tabela 6 - Modelos

O treino foi realizado localmente em vez do Roboflow, utilizando o script `train.py` com a biblioteca Ultralytics. Todas as configurações de treino são reproduzíveis a partir dos ficheiros `train\_config.yaml` incluídos em cada pasta de modelo.

3.2 Hiperparâmetros

Parâmetro	Valor
Optimizer	Auto (SGD)
Learning Rate (lr0)	0.01
LR Final (lrf)	0.01
Momentum	0.937
Weight Decay	0.0005
Warmup Epochs	3.0
Batch Size	16
Image Size	640×640
AMP	Ativado

Tabela 7 - Hiperparâmetros

3.3 Hardware Utilizado

- **GPU:** NVIDIA GeForce RTX 4060 (8GB VRAM)
- **CPU:** AMD Ryzen 7 5700X (16 threads @ 4.65 GHz)
- **RAM:** 32 GB DDR4
- **SO:** Windows 11

Tempos de treino:

- Nano Shelves (50 epochs): ~1.1 horas
- Small Shelves (150 epochs): ~4.7 horas
- Nano SKU (50 epochs): ~5.2 horas
- Nano Pallets (50 epochs): ~6 minutos

4. Resultados da Avaliação

4.1 Métricas Padrão no Conjunto de Validação

Modelo	mAP@0.5	mAP@0.5:0.95	Precision	Recall
Nano Shelves (50ep)	0.867	0.506	0.879	0.811
Small Shelves (150ep)	0.865	0.499	0.884	0.827
Nano SKU (50ep)	0.899	0.553	0.901	0.840
Nano Pallets (50ep)	0.987	0.758	0.960	0.976

Tabela 8 - Métricas nos modelos

As pastas de cada modelo incluem exemplos visuais de previsões corretas (`val\_batch\*\_pred.jpg`) e as labels reais (`val\_batch\*\_labels.jpg`), bem como matrizes de confusão normalizadas e curvas de treino (`results.png`).

4.2 Análise de Resultados e Erro

A tabela seguinte apresenta os resultados desagregados por classe para cada modelo. Uma vez que o dataset contém apenas 1 classe (item), os resultados por classe coincidem com os resultados globais.

Modelo	Classe	Instâncias	Precision	Recall	mAP@0.5	mAP@0.5:0.95
Nano Shelves (50ep)	item	—	0.879	0.811	0.867	0.506
Small Shelves (150ep)	item	—	0.884	0.827	0.865	0.499
Nano SKU (50ep)	item	—	0.901	0.840	0.899	0.553
Nano Pallets (50ep)	item	—	0.960	0.976	0.987	0.758

Tabela 9 - Análise resultados

Observação fundamental: O modelo Nano treinado no SKU-110K (11k imagens) superou significativamente os dois modelos treinados no dataset Shelves (1.6k imagens), mesmo usando a mesma arquitetura mais leve (Nano). Isto demonstra que a **qualidade e diversidade do dataset** é mais determinante para o desempenho do que o tamanho da arquitetura da rede.

Comparação Nano vs Small no mesmo dataset: O modelo Small (150 épocas) obteve métricas praticamente idênticas ao Nano (50 épocas) — mAP50 de 0.865 vs 0.867. Isto indica que o estrangulamento (bottleneck) reside no dataset e não na capacidade da rede. O modelo Nano é preferível por ser mais rápido (~3.2ms vs ~5.5ms).

Modos comuns de falha:

- **Falsos positivos:** Etiquetas de preço coloridas podem ser detetadas como produtos quando o limiar de confiança está muito baixo (<0.3).
- **Falsos negativos:** Produtos em zonas de sombra ou com embalagens muito escuras podem não ser detetados.
- **Fusão de bounding boxes:** Produtos muito próximos uns dos outros podem ocasionalmente ser fundidos numa única deteção.

Mitigações sugeridas:

- Utilizar limiar de confiança ≥ 0.50 para produção.
- Para ambientes com iluminação deficiente, reduzir para 0.35 com supervisão humana.
- Para produção industrial, considerar treino com dados específicos do ambiente-alvo.

5. Notas de Implementação

5.1 Aplicação de Demonstração

Foi desenvolvida uma aplicação web interativa utilizando **Streamlit**, com 5 funcionalidades principais organizadas em tabs:

1. **Inferência** — Upload de imagem, seleção de modelo via dropdown, visualização com bounding boxes, tabela de detecções estruturada com classe/confiança/coordenadas, e exportação JSON.




Figura 1 - Inferência

2. **Comparar Modelos** — Comparação visual lado a lado entre dois modelos selecionados sobre a mesma imagem.




Figura 2 - Comparar modelos

3. **Webcam ao Vivo** — Feed de vídeo em tempo real com inferência YOLO, permitindo auditoria visual instantânea de prateleiras.




Figura 3 - Webcam ao vivo

4. **Dashboard** — Painel com métricas comparativas dos 4 modelos, curvas de aprendizagem (lidas dos CSVs reais de treino), e matrizes de confusão.




Figura 4 - Dashboard

5. **Histórico** — Seleção de registo via dropdown, visualização com bounding boxes, tabela de deteções estruturada com classe/confiança/coordenadas, e exportação JSON.




Figura 5 - Histórico

5.2 Velocidade de Inferência e Tamanho dos Modelos

Modelo	Tamanho do Ficheiro	Inferência (GPU)	Arquitetura
Nano Shelves	6.25 MB	~3.2 ms	YOLOv8n
Small Shelves	22.5 MB	~5.5 ms	YOLOv8s
Nano SKU	6.25 MB	~3.2 ms	YOLOv8n
Nano Pallets	6.25 MB	~3.2 ms	YOLOv8n

Tabela 10 - Velocidade e tamanho dos modelos

Os modelos Nano são altamente viáveis para edge computing e dispositivos com recursos limitados.

5.3 Parâmetros e Configurações

- **Limiar de confiança recomendado:** 0.50 (padrão). Configurável na barra lateral da aplicação entre 0.10 e 1.00.
- **Resolução de input:** 640×640 (normalização automática pelo YOLOv8).
- **Formato de saída:** Bounding boxes em formato YOLO + JSON exportável com classe, confiança e coordenadas.

5.4 Ponto de Entrada para Inferência (CLI)

Além da aplicação gráfica, é fornecido um script CLI (`infer.py`) para inferência direta:

```
python infer.py --model modelos/yolov8n_sku/weights.pt --image caminho/imagem.jpg --conf 0.5
```

Este produz:

- Imagem anotada com bounding boxes guardada em disco.
- Saída JSON estruturada com todas as deteções (impressa no terminal e guardada num ficheiro `\_detections.json`).

6. Conclusões e Trabalho Futuro

O projeto demonstrou com sucesso a viabilidade de sistemas de deteção de objetos para monitorização de prateleiras em ambientes industriais. A principal conclusão técnica é que **a dimensão e diversidade do dataset são fatores mais determinantes que a complexidade da arquitetura** — o modelo Nano treinado no SKU-110K (11k imagens) superou o modelo Small treinado num dataset 7× mais pequeno.

Trabalho futuro planeado:

- Integração de leitura de códigos QR/barras para identificação automática de produtos.
- Implementação de lógica de deteção de ruturas de stock (colunas sem produtos).
- Treino com múltiplas classes para diferenciação de categorias de produto.
- Validação em ambientes industriais reais com câmaras fixas.

7. Bibliography

Goldman, E. e. (s.d.). Precise Detection in Densely Packed Scenes. *CVPR 2019*. Obtido de CVPR 2019. (Dataset SKU-110K).

Jocher, G. C. (2023). *Ultralytics YOLO*. Obtido de <https://github.com/ultralytics/ultralytics>

Roboflow. (2024). *Computer Vision Tools and Platform*. Obtido de <https://roboflow.com/>